Практическая 2 (Саттаров Булат Рамилевич ЭФМО-01-25)

Задание

Загрузите файл winequality-red.csv (с помощью pd.read_csv).

Последний столбец отвечает за качество вина. Будем считать, что хорошее вино начинается с цифры 7 и выше. Остальное вино будем счиатать некачественным.

Сделайте классификацию вина по данному датасету. Два класса "Хорошее" и "Не качественное". Результатом будем считать уравнение гиперповерхности на гиперпространстве параметров, отделяющее один класс от другого.

```
from sklearn.linear_model import LogisticRegression
import matplotlib.pyplot as plt
import seaborn as sns
import numpy as np
import pandas as pd
```

Загрузка выборки

```
from pathlib import Path

csv_path = Path('winequality-red.csv')

try:
    wine_dataset = pd.read_csv(csv_path, sep=';')
    if wine_dataset.shape[1] == 1:
        wine_dataset = pd.read_csv(csv_path)
except Exception:
    wine_dataset = pd.read_csv(csv_path)

wine_dataset.head()
```

```
   fixed acidity  volatile acidity  citric acid  residual sugar
chlorides  \
0            7.4              0.70         0.00             1.9
0.076
1            7.8              0.88         0.00             2.6
0.098
2            7.8              0.76         0.04             2.3
0.092
3           11.2              0.28         0.56             1.9
0.075
4            7.4              0.70         0.00             1.9
```

```
0.076

   free sulfur dioxide  total sulfur dioxide  density    pH  sulphates
\
0                 11.0                  34.0   0.9978  3.51       0.56

1                 25.0                  67.0   0.9968  3.20       0.68

2                 15.0                  54.0   0.9970  3.26       0.65

3                 17.0                  60.0   0.9980  3.16       0.58

4                 11.0                  34.0   0.9978  3.51       0.56


   alcohol  quality
0      9.4        5
1      9.8        5
2      9.8        5
3      9.8        6
4      9.4        5
```

Множество объектов

В данной задаче множество объектов описывается $n=11$ признаками:

1. fixed acidity
2. volatile acidity
3. citric acid
4. residual sugar
5. chlorides
6. free sulfur dioxide
7. total sulfur dioxide
8. density
9. pH
10. sulphates
11. alcohol

```
print('Размер выборки составляет l={}
объектов.'.format(len(wine_dataset)))
```

```
Размер выборки составляет l=1599 объектов.
```

```
analysis_dataset = wine_dataset.copy()
analysis_dataset['класс'] = np.where(analysis_dataset['quality'] >= 7,
'Хорошее', 'Не качественное')

analysis_dataset['класс'].value_counts()
```

```
класс
Не качественное    1382
Хорошее             217
Name: count, dtype: int64
```

```
plt.figure(figsize=(6, 4))
sns.countplot(data=analysis_dataset, x='класс')
plt.title('Распределение классов')
plt.show()
```

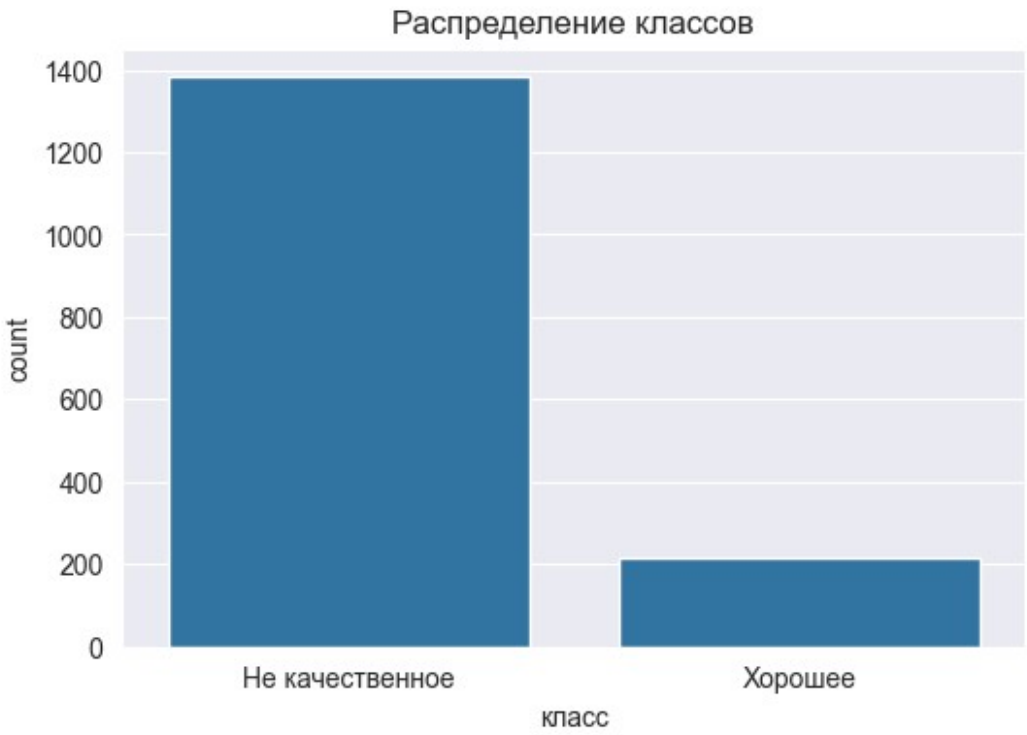


```
plot_columns = ['alcohol', 'volatile acidity', 'sulphates', 'citric
acid', 'класс']
sns.pairplot(analysis_dataset[plot_columns], hue='класс', height=2)
plt.show()
```

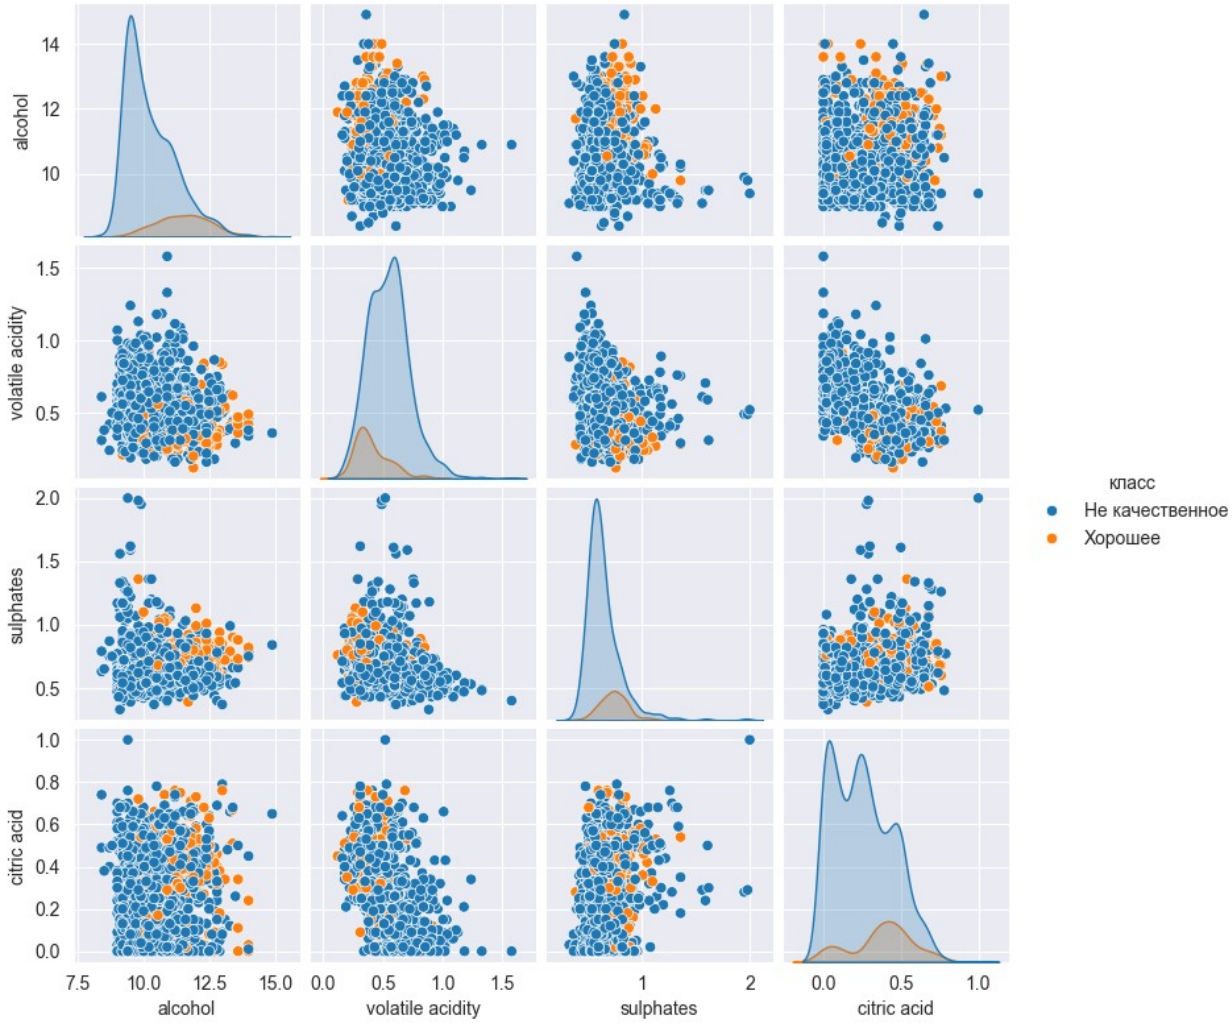

Из графиков видно, что классы пересекаются, но по ряду признаков наблюдается различие. Например, хорошие вина в среднем чаще имеют более высокий `alcohol` и `sulphates`, а также более низкий `volatile acidity`. Полного линейного разделения на всех проекциях нет, поэтому задача не является совсем простой, но логистическая регрессия может построить разделяющую гиперплоскость в пространстве признаков.

Построение модели

Преобразование данных

Преобразуем исходную задачу к бинарной классификации. Классы закодируем целыми числами -1 и 1:

- `Не качественное` $\to -1$
- `Хорошее` $\to 1$

```
binary_dataset = wine_dataset.copy()
binary_dataset['класс'] = np.where(binary_dataset['quality'] >= 7, 1,
```

```
-1)
binary_dataset.head()
```

```
   fixed acidity  volatile acidity  citric acid  residual sugar
chlorides  \
0            7.4              0.70         0.00             1.9
0.076
1            7.8              0.88         0.00             2.6
0.098
2            7.8              0.76         0.04             2.3
0.092
3           11.2              0.28         0.56             1.9
0.075
4            7.4              0.70         0.00             1.9
0.076

   free sulfur dioxide  total sulfur dioxide  density    pH  sulphates
\
0                 11.0                  34.0   0.9978  3.51       0.56

1                 25.0                  67.0   0.9968  3.20       0.68

2                 15.0                  54.0   0.9970  3.26       0.65

3                 17.0                  60.0   0.9980  3.16       0.58

4                 11.0                  34.0   0.9978  3.51       0.56


   alcohol  quality  класс
0      9.4        5     -1
1      9.8        5     -1
2      9.8        5     -1
3      9.8        6     -1
4      9.4        5     -1
```

```
X = binary_dataset.drop(columns=['quality', 'класс']).values
y = binary_dataset['класс'].values.reshape(-1)
X = np.array(np.hstack([X, np.ones([len(X), 1])]), dtype=np.float64)
y = np.array(y, dtype=np.int64)

X.shape, y.shape
```

```
((1599, 12), (1599,))
```

```
model = LogisticRegression(random_state=0, max_iter=5000,
fit_intercept=False)
_ = model.fit(X, y)
```

Вектор оптимальных параметров

```
model.coef_

array([[-0.06335039, -2.77554041,  0.24681499,  0.10262266, -
1.58158146,
         0.01390926, -0.01722415, -1.43621234, -2.53131255,
2.15950301,
         0.92392583, -1.42567304]])
```