С помощью метода kNN определить качество красного вина. Использовать датасет winequality-red.csv, который находится в папке data. Для этого разделить набор данных на обучающий и тестовый набор и обучим нашу модель в обучающем наборе. Построить матрицу путаницы. Сделать выводы по полученным результатам.

```
import warnings
warnings.filterwarnings('ignore')

import numpy as np
import pandas as pd
import seaborn as sns
import matplotlib.pyplot as plt
import itertools

from sklearn.model_selection import train_test_split
from sklearn.neighbors import KNeighborsClassifier
from sklearn.metrics import classification_report, confusion_matrix
from sklearn.pipeline import Pipeline
from sklearn.preprocessing import StandardScaler

sns.set_theme(style='darkgrid')
plt.rcParams['figure.figsize'] = (10, 5)
%matplotlib inline

df_raw = pd.read_csv('winequality-red.csv')
df = pd.DataFrame(df_raw)

df.head()
```

```
   fixed acidity  volatile acidity  citric acid  residual sugar
chlorides  \
0            7.4              0.70         0.00             1.9
0.076
1            7.8              0.88         0.00             2.6
0.098
2            7.8              0.76         0.04             2.3
0.092
3           11.2              0.28         0.56             1.9
0.075
4            7.4              0.70         0.00             1.9
0.076

   free sulfur dioxide  total sulfur dioxide  density    pH  sulphates
\
0                 11.0                  34.0   0.9978  3.51       0.56

1                 25.0                  67.0   0.9968  3.20       0.68

2                 15.0                  54.0   0.9970  3.26       0.65
```

```
3                  17.0                   60.0   0.9980  3.16       0.58

4                  11.0                   34.0   0.9978  3.51       0.56


   alcohol  quality
0      9.4        5
1      9.8        5
2      9.8        5
3      9.8        6
4      9.4        5
```

```
df.info()
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 1599 entries, 0 to 1598
Data columns (total 12 columns):
 #   Column                Non-Null Count  Dtype
---  ------                --------------  -----
 0   fixed acidity         1599 non-null   float64
 1   volatile acidity      1599 non-null   float64
 2   citric acid           1599 non-null   float64
 3   residual sugar        1599 non-null   float64
 4   chlorides             1599 non-null   float64
 5   free sulfur dioxide   1599 non-null   float64
 6   total sulfur dioxide  1599 non-null   float64
 7   density               1599 non-null   float64
 8   pH                    1599 non-null   float64
 9   sulphates             1599 non-null   float64
 10  alcohol               1599 non-null   float64
 11  quality               1599 non-null   int64
dtypes: float64(11), int64(1)
memory usage: 150.0 KB
```

```
df.describe()
```

```
       fixed acidity  volatile acidity  citric acid  residual sugar  \
count    1599.000000       1599.000000  1599.000000     1599.000000
mean        8.319637          0.527821     0.270976        2.538806
std         1.741096          0.179060     0.194801        1.409928
min         4.600000          0.120000     0.000000        0.900000
25%         7.100000          0.390000     0.090000        1.900000
50%         7.900000          0.520000     0.260000        2.200000
75%         9.200000          0.640000     0.420000        2.600000
max        15.900000          1.580000     1.000000       15.500000

         chlorides  free sulfur dioxide  total sulfur dioxide
density  \
count  1599.000000          1599.000000           1599.000000
1599.000000
mean      0.087467            15.874922             46.467792
```

```
0.996747
std       0.047065            10.460157             32.895324
0.001887
min       0.012000             1.000000              6.000000
0.990070
25%       0.070000             7.000000             22.000000
0.995600
50%       0.079000            14.000000             38.000000
0.996750
75%       0.090000            21.000000             62.000000
0.997835
max       0.611000            72.000000            289.000000
1.003690

                 pH    sulphates      alcohol      quality
count  1599.000000  1599.000000  1599.000000  1599.000000
mean      3.311113     0.658149    10.422983     5.636023
std       0.154386     0.169507     1.065668     0.807569
min       2.740000     0.330000     8.400000     3.000000
25%       3.210000     0.550000     9.500000     5.000000
50%       3.310000     0.620000    10.200000     6.000000
75%       3.400000     0.730000    11.100000     6.000000
max       4.010000     2.000000    14.900000     8.000000
```

```
df['target'] = np.where(df['quality'] >= 7, 'Качественное',
'Некачественное')
df['target'].value_counts()
```

```
target
Некачественное    1382
Качественное       217
Name: count, dtype: int64
```

```
temp_df = df.copy()

sns.countplot(x='target', hue='target', data=temp_df, palette='tab10')
plt.title('Распределение классов качества')
plt.xlabel('Класс')
plt.ylabel('Количество объектов')
plt.show()
```

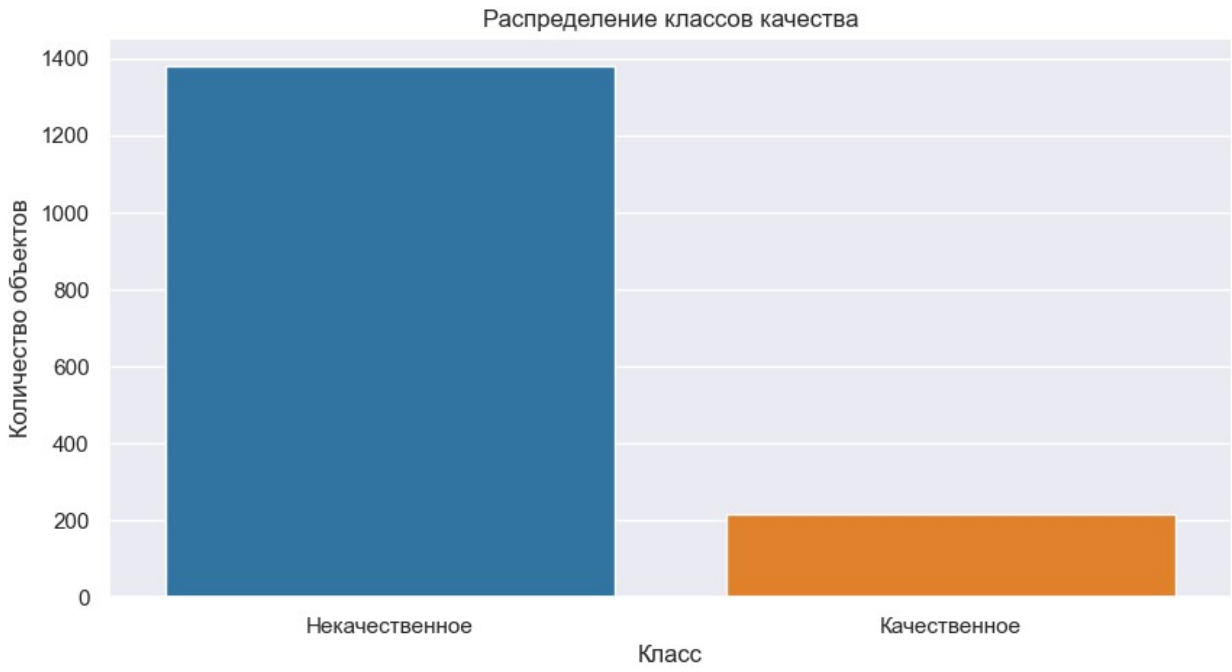

Из графика выше видно, что классы распределены неравномерно.
Некачественных вин в датасете заметно больше, чем качественных.
Тем не менее для данной работы такой вид бинарной классификации удобен и позволяет явно разделить вина на две группы.

```
pairplot_columns = ['alcohol', 'volatile acidity', 'sulphates',
'citric acid', 'target']
sns.pairplot(temp_df[pairplot_columns], hue='target', palette='tab10')
plt.show()
```

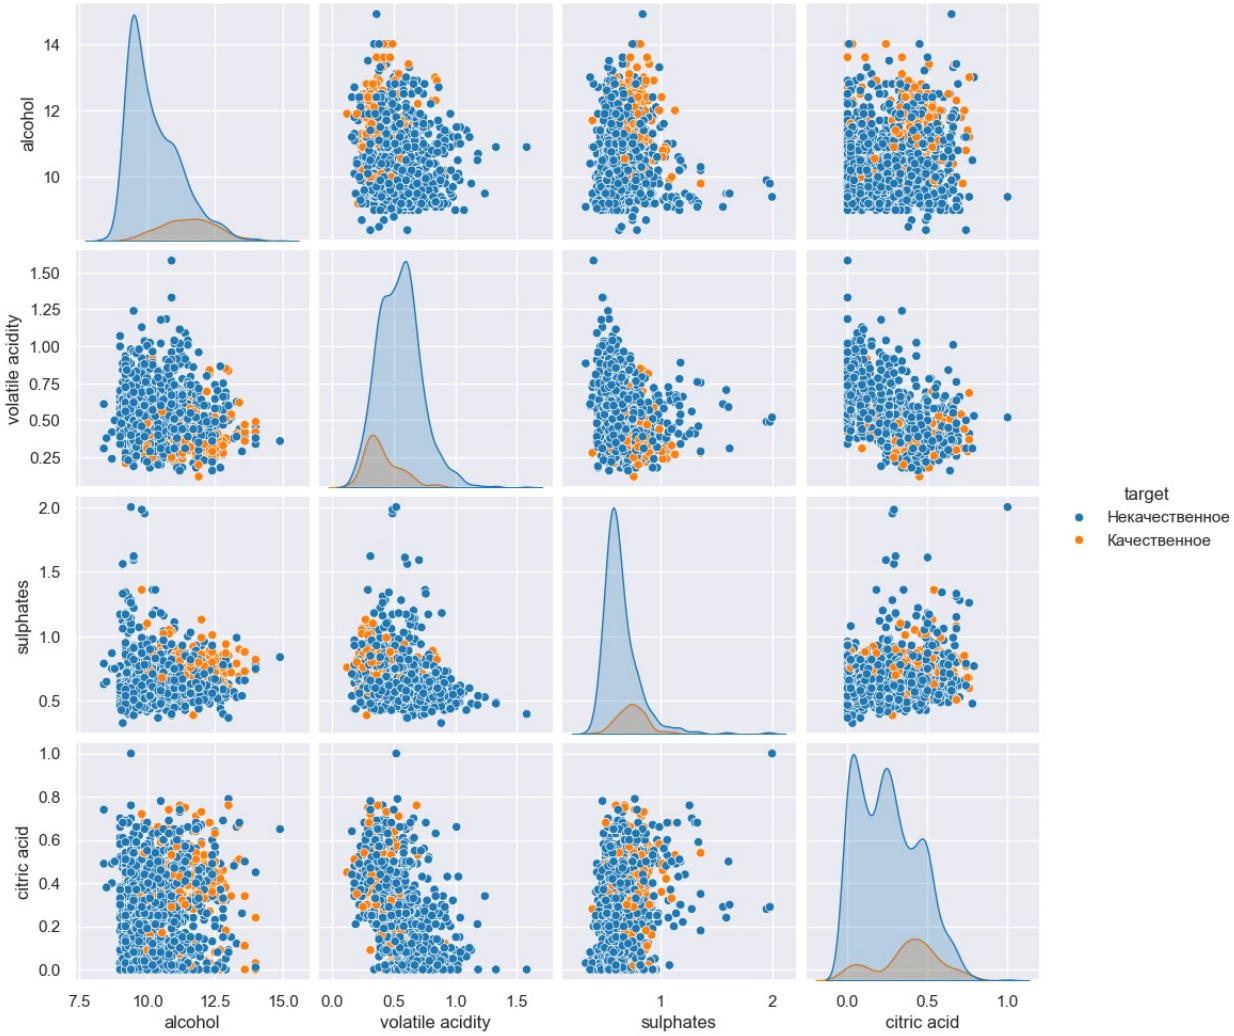

На графике выше можно увидеть взаимосвязь между наиболее показательными признаками.
Для части объектов наблюдается пересечение классов, однако по ряду признаков можно заметить различия.
Например, качественные вина чаще имеют более высокий `alcohol`, более низкий `volatile acidity` и несколько более высокие `sulphates`.

```
def display_confusion_matrix(
    matrix, labels=None, title="Confusion Matrix", xlabel="Predicted",
    ylabel="Actual", figsize=None, cmap="Blues", vmin=None, vmax=None
):
    if labels is None:
        labels = range(len(matrix))

    if figsize is None:
        figsize = (7, 5)

    plt.figure(figsize=figsize)
```

```
    plt.imshow(matrix, interpolation='nearest', cmap=cmap, vmin=vmin,
vmax=vmax)
    plt.title(title)
    plt.colorbar()

    tick_marks = np.arange(len(labels))
    plt.xticks(tick_marks, labels)
    plt.yticks(tick_marks, labels)

    thresh = matrix.max() / 2. if matrix.size else 0
    for i, j in itertools.product(range(matrix.shape[0]),
range(matrix.shape[1])):
        plt.text(
            j, i, matrix[i, j],
            horizontalalignment="center",
            color="white" if matrix[i, j] > thresh else "black"
        )

    plt.tight_layout()
    plt.ylabel(ylabel)
    plt.xlabel(xlabel)
    plt.show()
```

Модель на разделенном наборе данных

Теперь разделим набор данных на обучающую и тестовую выборки.
Обучение будет выполняться на обучающей части, а оценка качества классификации – на тестовой.

```
X = df.drop(['quality', 'target'], axis=1)
y = df['target']

X_train, X_test, y_train, y_test = train_test_split(
    X, y,
    stratify=y,
    test_size=0.2,
    random_state=42
)

knn = Pipeline([
    ('scaler', StandardScaler()),
    ('knn', KNeighborsClassifier(n_neighbors=5))
])

knn.fit(X_train, y_train)
```

```
Pipeline(steps=[('scaler', StandardScaler()), ('knn',
KNeighborsClassifier())])
```

```
preds = knn.predict(X_test)
labels = np.array(['Некачественное', 'Качественное'])
print(classification_report(y_test, preds))
```

```
                 precision    recall  f1-score   support

  Качественное       0.50      0.33      0.39        43
Некачественное       0.90      0.95      0.92       277

      accuracy                           0.87       320
     macro avg       0.70      0.64      0.66       320
  weighted avg       0.85      0.87      0.85       320
```

```
matrix = confusion_matrix(y_test, preds, labels=labels,
normalize=None)
print(matrix)

display_confusion_matrix(matrix, labels, title='Матрица путаницы на
тестовой выборке')
```

```
[[263  14]
 [ 29  14]]
```

По матрице путаницы и отчету классификации видно, что модель лучше распознает класс некачественных вин, так как этот класс представлен в датасете сильнее.
При этом качественные вина также отделяются по совокупности признаков, хотя ошибки классификации для них встречаются чаще.

В работе был применен метод k-ближайших соседей для определения качества красного вина по физико-химическим характеристикам из датасета `winequality-red.csv`.
Целевая переменная была преобразована в два класса: качественное вино (`quality >= 7`) и некачественное вино (`quality < 7`).
Были изучены структура и распределение данных, построены несколько моделей KNN для разных наборов признаков, а также получены матрицы путаницы.
Наиболее качественный результат показала модель, использующая все признаки и обученная на разделенных обучающей и тестовой выборках.