Практическая 4 (Саттаров Булат Рамилевич ЭФМО-01-25)

Задание

Реализовать расчеты способами а и б для набора данных из файла insclass_train.csv/ Для 151 406 договоров страхования транспортных средств известны значения ряда признаков, в том числе пол, возраст, стаж вождения и коэффициент бонус-малус водителя, тип, марка, модель, год выпуска, страна – производитель, мощность и объем двигателя, а также признак target, равный 1, если заключение договора с клиентом является рисковым, и 0 в противном случае (файл insclass_train.csv).

Требуется построить модель, предсказывающую значение признака target для 22 624 договоров из тестового набора данных (файл insclass_test.csv).

```
import time
import numpy as np
import pandas as pd
import matplotlib.pyplot as plt

from sklearn.model_selection import train_test_split
from sklearn.metrics import accuracy_score, f1_score, confusion_matrix

# Загрузка данных
df = pd.read_csv('insclass_train.csv')
print('Размер данных:', df.shape)
df.head()
```

```
Размер данных: (151406, 29)

  variable_1  variable_2  variable_3  variable_4 variable_5
variable_6  \
0       w200           0           0          14         q2
98.0
1       w160           0           0           7        q11
106.0
2       w200           0           0           4         q3
123.0
3       w200           0           0           9         q3
102.0
4       w200           0           0          18        q20
117.0

   variable_7  variable_8  variable_9  variable_10  ...
variable_20  \
0         NaN         0.0         NaN            0  ...            C
```

```
1          NaN          0.0          NaN             0  ...             C

2          NaN          0.0          NaN             0  ...             B

3          NaN          0.0          NaN             0  ...             C

4          NaN          0.0          NaN             0  ...             C


   variable_21  variable_22  variable_23  variable_24  variable_25  \
0           j2          h45            0          0.0            0
1          j33         h234            0          1.0            0
2          j12          h28            0          0.0            0
3          j12          h64            0          1.0            0
4         j111         h991            0          1.0            0

   variable_26  variable_27  variable_28 target
0            1    19.323463           t1      0
1            1    41.177900           t1      0
2            1     3.614395           t1      0
3            0    49.041674           t1      0
4            0    17.909612           t1      0

[5 rows x 29 columns]
```

```python
# Проверка пропусков
df.isna().sum().sort_values(ascending=False).head(10)
```

```
variable_15    151393
variable_9     134436
variable_7      95639
variable_8      29899
variable_14      2927
variable_24      2207
variable_27      2067
variable_13      1657
variable_12      1528
variable_6        111
dtype: int64
```

Подготовка данных

```python
X = df.drop(columns=['target']).copy()
Y = df['target'].astype(int).copy()

numeric_cols = X.select_dtypes(include=[np.number]).columns.tolist()
categorical_cols = [col for col in X.columns if col not in
numeric_cols]
```

```python
# Заполнение пропусков
for col in numeric_cols:
    X[col] = X[col].fillna(X[col].median())

for col in categorical_cols:
    X[col] = X[col].fillna(X[col].mode()[0])

X = pd.get_dummies(X, drop_first=True)

x_train, x_test, Y_train, Y_test = train_test_split(
    X, Y,
    test_size=0.2,
    random_state=42,
    stratify=Y
)

mu = x_train.mean(axis=0)
sigma = x_train.std(axis=0)
sigma[sigma == 0] = 1

x_train = (x_train - mu) / sigma
x_test = (x_test - mu) / sigma

x_train = x_train.to_numpy(dtype=float)
x_test = x_test.to_numpy(dtype=float)
Y_train = Y_train.to_numpy(dtype=float).reshape(-1, 1)
Y_test = Y_test.to_numpy(dtype=float).reshape(-1, 1)

x_train = np.hstack([np.ones((x_train.shape[0], 1)), x_train])
x_test = np.hstack([np.ones((x_test.shape[0], 1)), x_test])

print(x_train.shape, x_test.shape)
```

```
(121124, 1746) (30282, 1746)
```

```python
class LogisticRegressionGD(object):
    def __init__(self):
        self.a = None

    def sigmoid(self, z):
        z = np.clip(z, -250, 250)
        return 1 / (1 + np.exp(-z))

    def predict(self, x):
        return self.sigmoid(x @ self.a)

    def predict_class(self, x):
        return (self.predict(x) > 0.5).astype(int)

    def coefs(self):
        return self.a
```

```
    def LogLikelihood(self, p, Y):
        p = np.clip(p, 1e-12, 1 - 1e-12)
        return (Y * np.log(p) + (1 - Y) * np.log(1 - p)).mean()

    def CrossEntropy(self, p, Y):
        p = np.clip(p, 1e-12, 1 - 1e-12)
        return (-Y * np.log(p) - (1 - Y) * np.log(1 - p)).mean()

    def accuracy(self, x, Y):
        return (self.predict_class(x) == Y).mean()

    def fit(self, x, Y, alpha=0.01, epsylon=0.01, max_steps=1000,
Rtype="LL"):
        self.a = np.zeros(x.shape[1]).reshape(x.shape[1], 1)
        steps, errors = [], []
        step = 0

        for _ in range(max_steps):
            p = self.predict(x)

            if Rtype == "LL":
                new_error = self.LogLikelihood(p, Y)
                dT_a = x.T @ (Y - p) / x.shape[0]
                self.a += alpha * dT_a

            elif Rtype == "CE":
                new_error = self.CrossEntropy(p, Y)
                dT_a = x.T @ (p - Y) / x.shape[0]
                self.a -= alpha * dT_a

            else:
                raise ValueError("Rtype должен быть 'LL' или 'CE'")

            step += 1
            steps.append(step)
            errors.append(new_error)

        return steps, errors
```

Обучение модели способом a

```
alpha = 0.05
max_steps = 1000

model_LL = LogisticRegressionGD()
start_LL = time.time()
steps_LL, errors_LL = model_LL.fit(x_train, Y_train, alpha=alpha,
max_steps=max_steps, Rtype='LL')
```

```
time_LL = time.time() - start_LL

pred_LL = model_LL.predict_class(x_test)
acc_LL = accuracy_score(Y_test, pred_LL)
f1_LL = f1_score(Y_test, pred_LL)

print('Время обучения:', round(time_LL, 4), 'сек')
print('Accuracy:', acc_LL)
print('F1:', f1_LL)
print('Матрица ошибок:')
print(confusion_matrix(Y_test, pred_LL))
```

```
Время обучения: 38.3764 сек
Accuracy: 0.9107390529027145
F1: 0.2005323868677906
Матрица ошибок:
[[27240   150]
 [ 2553   339]]
```

Обучение модели способом б

```
model_CE = LogisticRegressionGD()
start_CE = time.time()
steps_CE, errors_CE = model_CE.fit(x_train, Y_train, alpha=alpha,
max_steps=max_steps, Rtype='CE')
time_CE = time.time() - start_CE

pred_CE = model_CE.predict_class(x_test)
acc_CE = accuracy_score(Y_test, pred_CE)
f1_CE = f1_score(Y_test, pred_CE)

print('Время обучения:', round(time_CE, 4), 'сек')
print('Accuracy:', acc_CE)
print('F1:', f1_CE)
print('Матрица ошибок:')
print(confusion_matrix(Y_test, pred_CE))
```

```
Время обучения: 38.4575 сек
Accuracy: 0.9107390529027145
F1: 0.2005323868677906
Матрица ошибок:
[[27240   150]
 [ 2553   339]]
```

Графики изменения

```
plt.figure(figsize=(10, 5))
plt.plot(steps_LL, errors_LL)
plt.title('Изменение Log-Likelihood')
plt.xlabel('Шаг')
```

```
plt.ylabel('Log-Likelihood')
plt.grid(True)
plt.show()
```

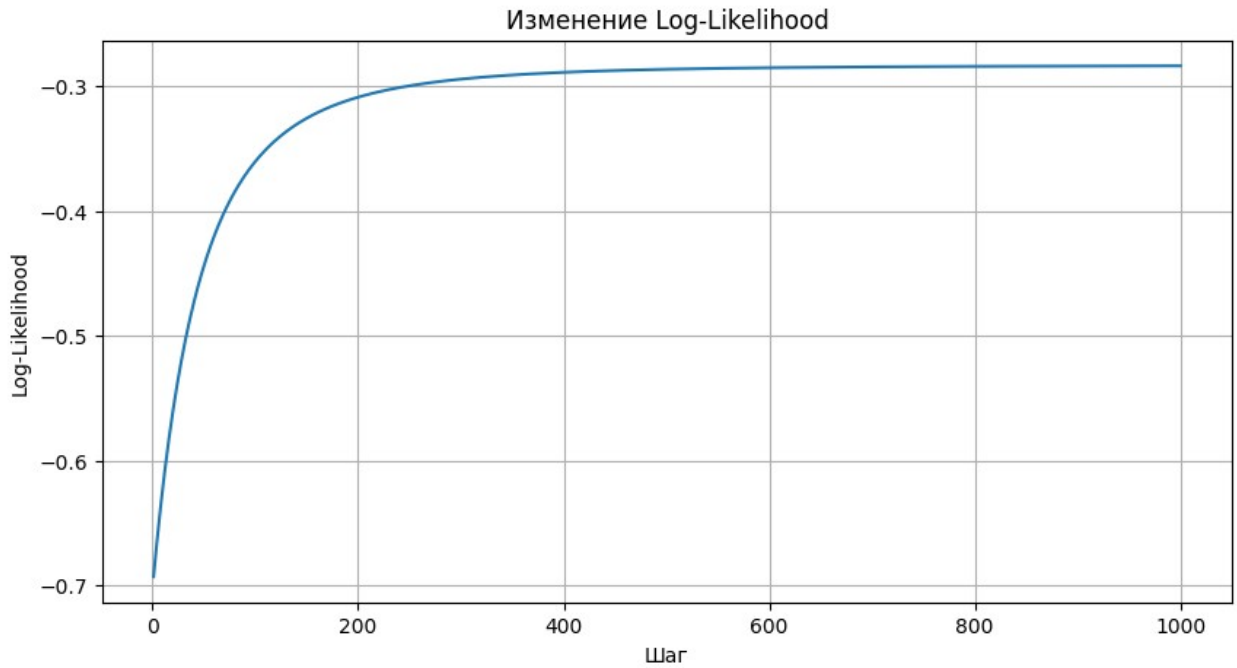


```
plt.figure(figsize=(10, 5))
plt.plot(steps_CE, errors_CE)
plt.title('Изменение Cross-Entropy')
plt.xlabel('Шаг')
plt.ylabel('Cross-Entropy')
plt.grid(True)
plt.show()
```

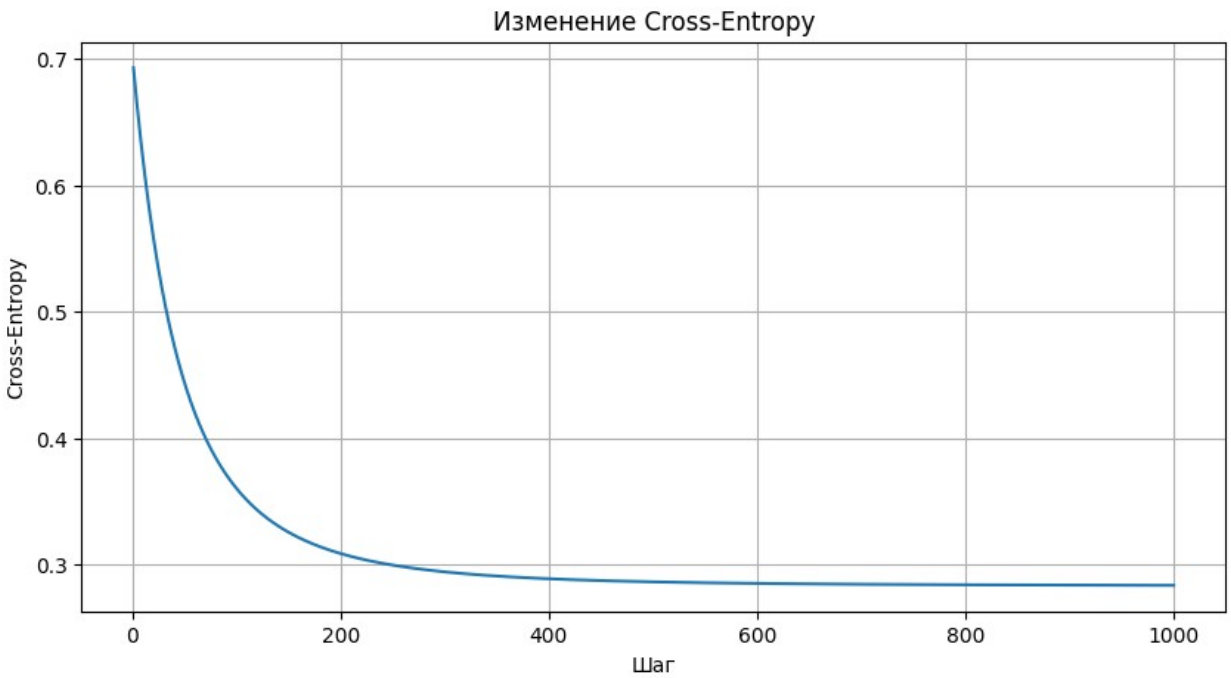

Сравнение результатов

```
results = pd.DataFrame({
    'Способ': ['а) Log-Likelihood', 'б) Cross-Entropy'],
    'alpha': [alpha, alpha],
    'max_steps': [max_steps, max_steps],
    'time_sec': [time_LL, time_CE],
    'accuracy': [acc_LL, acc_CE],
    'f1': [f1_LL, f1_CE]
})

results
```

```
              Способ  alpha  max_steps   time_sec  accuracy        f1
0  а) Log-Likelihood   0.05       1000  38.376410  0.910739  0.200532
1   б) Cross-Entropy   0.05       1000  38.457477  0.910739  0.200532
```

Вывод

Были реализованы два способа обучения бинарной логистической регрессии. В первом случае выполнялась максимизация Log-Likelihood методом градиентного подъема. Во втором случае выполнялась минимизация Cross-Entropy методом градиентного спуска. Для обоих способов использовались одинаковые значения скорости обучения и числа шагов.

После обучения модели были сравнены по времени выполнения, accuracy и F1-мере на тестовой выборке, полученной делением исходного набора данных в пропорции 80/20. Результаты обоих подходов должны получаться близкими, так как минимизация Cross-Entropy эквивалентна максимизации Log-Likelihood с противоположным знаком функции.